

SELÇUK ÜNİVERSİTESİ

Mühendislik Fakültesi

Türkçe Afet Tweet Sınıflandırması için QLoRA Tabanlı İnce Ayar: Küçük Dil Modelleri Üzerinde Karşılaştırmalı Bir Benchmark Çalışması

BÜYÜK DİL MODELLERİ (BDM) — Dönem Projesi Final Raporu

Hazırlayan: Mustafa Kırpık

Koordinasyon: Saliha Göçergi (LoRA çalışması)

Mayıs 2026

Özet

Bu çalışma, 2023 Kahramanmaraş depremleri sırasında paylaşılan Türkçe tweet'lerin beş operasyonel sınıfa (yardım talebi, kayıp bildirimi, altyapı hasarı, bağış/koordinasyon, diğer/ilgisiz) otomatik olarak ayrılması problemini ele almaktadır. Çalışmada 793 adet elle etiketlenmiş gerçek tweet'ten oluşan bir veri seti kullanılmış; sınırlı donanımda çalışabilen dört Küçük Dil Modeli (SmolLM2-360M, TinyLlama-1.1B, Qwen2.5-1.5B, Gemma-4-E2B) QLoRA (4-bit NormalFloat) yöntemiyle ince ayarlanmıştır. Sonuçlar, zero-shot temel çizginin görevde tamamen başarısız olduğunu (Macro-F1 0.094), QLoRA ince ayarının ise performansı çarpıcı biçimde artırdığını göstermektedir (en yüksek Macro-F1 0.914, Qwen2.5). Modeller arasında belirgin ancak doğrusal olmayan bir ölçek etkisi gözlenmiştir: 1–1.5 milyar parametre aralığı en iyi başarı-kaynak dengesini sağlarken, en büyük model Gemma-4-E2B (5B ham / efektif ~2B) küçük veri kümesinde aşırı uydurma yaşamış ve daha küçük modellerin gerisinde kalmıştır (Macro-F1 0.740). QLoRA'nın tepe GPU bellek kullanımı 1.81–9.73 GB aralığında kalmıştır. Çalışma, Saliha Göçerçi'nin LoRA çalışmasıyla koordineli yürütülmüş olup, LoRA-QLoRA karşılaştırması da kapsama dahildir.

Anahtar Kelimeler: QLoRA, Türkçe NLP, afet bilisiimi, küçük dil modelleri, parametre verimli ince ayar.

1. Giriş ve Problem Tanımı

Afet yönetiminde bilgi akışının hızı ve doğruluğu hayati önem taşır. 2023 Kahramanmaraş depremleri sırasında Twitter (X) platformu, etkilenen bireylerin acil yardım taleplerini ilettiği, kayıp bildirimlerinin yapıldığı ve lojistik koordinasyonun sağlandığı kritik bir kanal hâline gelmiştir. Paylaşılan verinin muazzam hacmi, bu bilgilerin manuel analiz edilmesini imkânsız kılar; otomatik sınıflandırma bir karar destek ihtiyacı olarak ortaya çıkar.

Bu projenin amacı, kısıtlı donanım kaynaklarında çalışabilen Küçük Dil Modellerini (SLM) QLoRA ile ince ayarlayarak Türkçe afet tweet'lerini yüksek doğrulukla sınıflandırmaktır. QLoRA; 4-bit NormalFloat kuantizasyonu, çift kuantizasyon ve sayfalı optimizasyon teknikleriyle, düşük maliyetli GPU'larda dahi yüksek performans elde etmeyi hedefler.

1.1. Araştırma Soruları

- 1B–1.5B parametre aralığındaki SLM'ler, QLoRA ile ince ayarlandığında Türkçe afet metinlerinde pratikte yeterli doğruluğa ulaşır mı?
- Model boyutu ile sınıflandırma başarısı arasındaki ilişki nedir; ölçek getirisi nerede doygunlaşır?
- Aynı ortam ve veriyle LoRA ile QLoRA arasındaki doğruluk–bellek dengesi nasıldır?

1.2. Katkılar

- Kaggle'daki açık "Turkey Earthquake Relief Tweets" havuzundan seçilen, beş sınıfa elle etiketlenmiş 793 örneklik Türkçe afet tweet veri seti.
- Üç SLM üzerinde zero-shot ve QLoRA performanslarını içeren karşılaştırmalı benchmark.
- Model boyutu–başarı ilişkisine dair ampirik bulgular ve sınıf bazlı hata analizi.
- Saliha Göçerçi'nin LoRA çalışmasıyla doğrudan LoRA–QLoRA karşılaştırması.

2. Literatür Özeti

Afet bilişimi (crisis informatics), bilişim teknolojilerinin afet hazırlık, müdahale ve iyileştirme süreçlerine entegrasyonunu inceleyen çok disiplinli bir alandır. Erken çalışmalar anahtar kelime tabanlı filtreleme ve istatistiksel yöntemlere dayanırken, güncel araştırmalar Transformer tabanlı mimarilerin bağlamsal temsil gücünden yararlanır.

2.1. Türkiye Odaklı Çalışmalar

Toraman ve arkadaşları (2023) "Tweets Under the Rubble" çalışmasında, Kahramanmaraş depreminin ilk saatlerinde paylaşılan milyonlarca tweet'i analiz ederek yardım çağrılarının tespitine odaklanmış ve BERTurk türü modellerle yüksek başarı elde etmiştir. Bu çalışma, Türkçe afet metni sınıflandırması için ilgili ve öncü bir literatür referansıdır; bu projenin veri kaynağı değildir (bizim verimiz ayrı bir Kaggle veri setinden gelmektedir; bkz. Bölüm 3). Söz konusu çalışmalar büyük, görev-özel modellerin gücünü gösterse de, edge cihaz uygulanabilirliği sınırlıdır; bu proje ise küçük modellerin parametre verimli ince ayarına odaklanır.

2.2. Küçük Dil Modelleri ve PEFT

SmolLM2 (360M), TinyLlama (1.1B) ve Qwen2.5 (1.5B) gibi SLM'ler, düşük VRAM ihtiyacıyla kısıtlı donanımda çalışabilir. Parametre verimli ince ayar (PEFT) yöntemlerinden LoRA, model ağırlıklarını dondurup düşük dereceli iki matrisin çarpımıyla güncelleme yaparak eğitilebilir parametre sayısını %1'in altına indirir. QLoRA ise bunu 4-bit NormalFloat kuantizasyonu, çift kuantizasyon ve sayfalı optimizasyonla birleştirerek VRAM kullanımını dramatik biçimde azaltır.

3. Veri Seti ve Ön İşleme

3.1. Veri Toplama ve Etiketleme

Çalışmada kullanılan ham tweet'ler, Kaggle üzerinde yayımlanmış açık erişimli "Turkey Earthquake Relief Tweets Dataset" (Ulku Tuncer Küçüktaş, 2023) veri setinden alınmıştır. Bu havuzdan seçilen 793 gerçek deprem tweet'i, bu proje kapsamında beş sınıfa elle etiketlenmiştir. Etiketleme, sınıf tanımlarına bağlı kalınarak manuel olarak yapılmıştır; yani ham metin Kaggle kaynağından gelirken, beş sınıflı etiketler tümüyle bu çalışmaya özgüdür. Bu yaklaşım, gürültülü zayıf etiketleme veya sentetik veri üretiminin yaratabileceği etiket gürültüsü ve örüntü yanlışlığını ortadan kaldırarak yüksek etiket kalitesi sağlamıştır.

Not (dürüstlük beyanı): Çalışmanın erken aşamasında, ham tweet havuzu için kural tabanlı zayıf etiketleme ve az örnekli sınıflar için şablon tabanlı sentetik üretim de denenmiştir. Ancak nihai çalışmada, etiket kalitesi ve değerlendirme bütünlüğü gerekçesiyle 793 örneklik elle etiketlenmiş set tercih edilmiş; zayıf etiketli/sentetik veriler kullanılmamıştır.

3.2. Sınıf Taksonomisi ve Dağılım

ID	Sınıf	Açıklama	Örnek Sayısı
0	Yardım Talebi	Acil yardım, kurtarma, malzeme çağrısı	289
1	Kayıp Bildirimi	Ulaşılamayan / kayıp kişi aramaları	98
2	Altyapı Hasarı	Yıkık bina, kapalı yol, şebeke kesintisi	100
3	Bağış/Koordinasyon	Bağış, IBAN, gönüllü, lojistik	105
4	Diğer/İlgisiz	Haber, taziye, eleştiri, off-topic	201
—	TOPLAM		793

Tablo 1. Sınıf taksonomisi ve etiket dağılımı (793 tweet)

3.3. Ön İşleme

Tweet'lere minimal ön işleme uygulanmıştır: URL'ler ve kullanıcı etiketleri (@kullanıcı → [USER]) anonimleştirilmiş, çoklu boşluklar normalize edilmiştir. Türkçe karakterler, hashtag'ler ve emoji'ler anlamsal değer taşıdığı için korunmuştur.

3.4. Veri Bölünmesi

Veri seti, sınıf dağılımı korunarak (stratified) %80/10/10 oranında bölünmüştür: 633 eğitim, 80 doğrulama, 80 test. Tekrarlanabilirlik için tüm bölünmeler seed=42 ile gerçekleştirilmiştir. Test setinin sınıf dağılımı: Yardım 29, Kayıp 10, Altyapı 10, Bağış 11, Diğer 20.

4. Yöntem

4.1. Modeller

Model	Parametre	HuggingFace ID
SmolLM2-360M-Instruct	360M	HuggingFaceTB/SmolLM2-360M-Instruct
TinyLlama-1.1B-Chat	1.1B	TinyLlama/TinyLlama-1.1B-Chat-v1.0
Qwen2.5-1.5B-Instruct	1.5B	Qwen/Qwen2.5-1.5B-Instruct
Gemma-4-E2B-it	5B ham / ~2B efektif	google/gemma-4-E2B-it (Unsloth)

Tablo 2. Kullanılan dört model (Gemma-4 multimodal; metin-only kullanım)

4.2. QLoRA ve Eğitim Formülasyonu

Modeller, talimat-takip (instruction-following) formatında üretken bir sınıflandırma görevine ince ayarlanmıştır: model, tweet'i içeren bir komuta karşılık doğru kategori adını üretmeyi öğrenir. Her model için kendi sohbet şablonu (apply_chat_template) kullanılmış, böylece farklı mimariler tek bir tutarlı boru hattıyla eğitilebilmiştir.

QLoRA bileşenleri: 4-bit NormalFloat (NF4) kuantizasyonu, çift kuantizasyon ve sayfalı optimizasyon. LoRA parametreleri: $r=16$, $\alpha=32$, dropout=0.05, hedef modüller [q_proj, k_proj, v_proj, o_proj]. Sadece tamamlama (completion) kısmının kaybı hesaplanmıştır.

5. Deneysel Kurulum

5.1. Donanım ve Hiperparametreler

Parametre	Değer
Donanım	Google Colab — NVIDIA T4 (16 GB)
Epoch	3
Batch size / grad. accum.	4 / 4 (efektif 16)
Max sequence length	2048 (Qwen) / varsayılan
Learning rate	2e-4
LR scheduler / warmup	Cosine / 0.03
Mixed precision	bf16 (T4 emülasyonlu)
Seed	42 (sabit)

Tablo 3. Eğitim hiperparametreleri

5.2. Değerlendirme Protokolü

İki aşamalı değerlendirme uygulanmıştır: (1) Zero-shot — ince ayar öncesi, prompt tabanlı; (2) QLoRA fine-tuned — test seti tamamında. Metrikler: Accuracy, Macro-F1 (sınıf dengesizliği için kritik), Weighted-F1, çıkarım süresi (ms/tweet), tepe GPU belleği ve eğitim süresi. Tahminler, modelin ürettiği kategori metninin ayrıştırılmasıyla (Türkçe altmetin eşleştirme) elde edilmiştir.

6. Sonuçlar

6.1. Standart Sonuç Tablosu

Model	Yöntem	Acc	Macro-F1	Weig-F1	Inf (ms)	GPU (GB)	Eğitim (s)
TinyLlama-1.1B	Zero-shot	0.262	0.094	0.125	—	—	—
SmolLM2-360M	QLoRA	0.662	0.588	0.663	1542	1.81	696
TinyLlama-1.1B	QLoRA	0.925	0.908	0.921	960	3.29	1697
Qwen2.5-1.5B	QLoRA	0.925	0.914	0.925	1120	5.07	2151
Gemma-4-E2B (5B)	QLoRA (Unsloth)	0.788	0.740	0.765	1798	9.73	718

Tablo 4. Standart sonuç tablosu (test seti, n=80, seed=42)

Eğitilebilir parametre oranları (QLoRA): SmolLM2 3.28M (%0.90), TinyLlama 4.5M (%0.41), Qwen2.5 4.36M (%0.28), Gemma-4 31.04M (%0.60 — Unsloth'un Gemma için önerdiği genişletilmiş hedef modüller). Tüm fine-tuned modeller test setinde 0/80 ayrıştırma hatası vermiştir; zero-shot ise 79/80 örnekte geçerli kategori üretememiştir.

6.2. Sınıf Bazlı F1 Skorları (QLoRA)

Sınıf	SmolLM2-360M	TinyLlama-1.1B	Qwen2.5-1.5B	Gemma-4-E2B
Yardım Talebi	0.85	0.95	0.95	0.86
Kayıp Bildirimi	0.38	0.95	0.89	0.46
Altyapı Hasarı	0.59	0.95	1.00	0.91
Bağış/Koordinasyon	0.42	0.74	0.78	0.76
Diğer/İlgisiz	0.70	0.95	0.95	0.71

Tablo 5. Sınıf bazlı F1 (vurgulu satır: Bağış/Koordinasyon — modellerin çoğunda zayıf nokta)

6.3. Değerlendirme

Zero-shot temel çizgi görevde tamamen çökmüştür (Macro-F1 0.094); model 80 örneğin 79'unda geçerli bir kategori bile üretememiş, %26.2'lik doğruluk yalnızca "Diğer" sınıfının taban oranının bir yansımasıdır. QLoRA ince ayarı bu tabloyu kökten değiştirmiş, Macro-F1 değerini 0.91 seviyesine taşımıştır — projenin temel bulgusu budur.

Modeller arasındaki ölçek etkisi doğrusal değildir: 360M → 1.1B geçişinde büyük bir sıçrama vardır (Macro-F1 0.588 → 0.908), ancak 1.1B → 1.5B (0.914) marjinaldir. En çarpıcı bulgu, modelimizin en büyüğü olan Gemma-4-E2B'nin (5B ham, ~2B efektif) küçük modellerin gerisinde kalmasıdır (Macro-F1 0.740). Bu,

küçük veri rejiminde "daha büyük her zaman daha iyi değildir" tezini destekler. Eğitim sırasında doğrulama kaybının (val loss 3.82) eğitim kaybından (0.003) çok daha yüksek olması, klasik bir aşırı uydurma sinyalidir. Olası nedenler: (i) Gemma-4 için Unsloth'un önerdiği genişletilmiş hedef modüller daha fazla eğitilebilir parametre (31M, diğerlerinin ~7 katı) ve daha hızlı aşırı uydurma; (ii) çok modlu (metin+görüntü+ses) mimarının saf metin sınıflandırması için optimum olmaması; (iii) T4 üzerinde fp16 emülasyonu. Bu, modelin gücü değil, hiperparametre-veri uyumsuzluğunun sonucudur ve veriyle birlikte LR/epoch'un modele özel ayarlanması gerektiğini gösterir.

Qwen2.5 en yüksek Macro-F1'i (0.914) elde etmiş, güçlü çok dilli/Türkçe eğitimini göstermiştir; ancak TinyLlama neredeyse aynı başarıyı (0.908) yaklaşık %35 daha düşük GPU belleğiyle (3.29 GB'a karşı 5.07 GB) sağlamıştır — verimlilik açısından dikkate değer bir bulgu. Gemma-4 ise Unsloth optimizasyonu sayesinde en hızlı eğitim süresine (718 s) sahiptir, fakat çıkarım süresi en uzundur (1798 ms/tweet).

QLoRA'nın bellek verimliliği tüm modellerde belirgindir: tepe GPU kullanımı 1.81–9.73 GB aralığında kalmıştır. Eşdeğer bir tam ince ayar onlarca GB gerektireceğinden, bu sonuç düşük maliyetli donanım hedefini doğrulamaktadır.

7. Hata Analizi ve Tartışma

7.1. Sınıflar Arası Karışıklık

En tutarlı hata deseni, Bağış/Koordinasyon sınıfının tüm modellerde en zayıf sınıf olmasıdır (F1: SmolLM2 0.42, TinyLlama 0.74, Qwen2.5 0.78). Bu sınıf en sık Yardım Talebi ile karışmaktadır; bunun nedeni, bağış/koordinasyon tweet'lerinin de sıklıkla malzeme, adres ve ihtiyaç ifadeleri içermesi, dolayısıyla yardım talepleriyle semantik olarak örtüşmesidir. Örneğin TinyLlama, 11 bağış örneğinin 4'ünü yanlış sınıflamış (2'si Yardım, 1'i Kayıp, 1'i Altyapı), Qwen2.5 ise 2'sini Yardım olarak işaretlemiştir.

En küçük model SmolLM2-360M, az örnekli sınıflarda (Kayıp 0.38, Bağış 0.42, Altyapı 0.59) belirgin biçimde başarısızdır; karışıklık matrisi bu üç sınıfın birbirine karıştığını göstermektedir. Buna karşılık TinyLlama ve Qwen2.5 bu sınıfları büyük ölçüde çözebilmiştir (Kayıp 0.95/0.89, Altyapı 0.95/1.00). Gemma-4 ise farklı bir hata desenine sahiptir: Kayıp Bildirimi'nde recall yalnızca 0.30'a düşmüş (10'da 3), ve 20 "Diğer" örneğinden 6'sını yanlışlıkla "Bağış/Koordinasyon" olarak işaretlemiştir. Bu desen, aşırı uydurma altında modelin baskın sınıflara yönlendiğini gösterir. Genel sonuç: model kapasitesi tek başına yeterli değildir; veri ve hiperparametrelerle uyumu kritiktir.

7.2. Recall Odaklı Yorum

Afet senaryosunda yanlış negatif (bir yardım çağrısını kaçırmak) yanlış pozitiften daha maliyetlidir. Bu açıdan en kritik sınıf olan Yardım Talebi'nde tüm orta/büyük modeller yüksek recall sağlamıştır (TinyLlama 0.97, Qwen2.5 1.00). Bağış sınıfındaki düşük recall ise, gerçek bağış/koordinasyon mesajlarının bir kısmının kaçırılabilirliğini gösterir; üretim ortamında bu sınıf için ek doğrulama önerilir.

7.3. LoRA vs QLoRA Karşılaştırması

Bu çalışmanın benchmark'a temel katkısı, Saliha Göçer'ini LoRA sonuçlarıyla yapılacak doğrudan karşılaştırmadır. Aynı veri seti, modeller ve seed kullanıldığından doğruluk ve kaynak tüketimi adil biçimde kıyaslanabilir.

[YER TUTUCU — LoRA-QLoRA karşılaştırma tablosu (Accuracy, Macro-F1, tepe GPU, eğitim süresi) — Saliha'nın LoRA sonuçları geldiğinde doldurulacak. Beklenti: benzer doğruluk, QLoRA lehine belirgin bellek tasarrufu.]

8. Sonuç, Limitasyonlar ve Etik

8.1. Sonuç

Dört Küçük Dil Modeli üzerinde yapılan QLoRA ince ayarı, Türkçe afet tweet sınıflandırmasında zero-shot temel çizgiye kıyasla çarpıcı bir iyileşme sağlamıştır (Macro-F1 0.094 → 0.914). Qwen2.5-1.5B en iyi sonucu vermiş, TinyLlama-1.1B ise neredeyse aynı başarıyı daha düşük bellekle elde ederek verimlilik açısından öne çıkmıştır. En büyük model Gemma-4-E2B beklenenden düşük performans vermiş (Macro-F1 0.740), küçük veri rejiminde "büyük her zaman daha iyi değildir" bulgusunu ortaya koymuştur. QLoRA, 10 GB'ın altında tepe bellekle düşük maliyetli donanımda etkili ince ayarı mümkün kılmıştır.

8.2. Bilinen Limitasyonlar

- Veri seti küçüktür (793 örnek); test seti yalnızca 80 örnek içerdiğinden az örnekli sınıflarda (Altyapı, Kayıp) metrik varyansı yüksek olabilir.
- Sonuçlar tek seed (42) ile raporlanmıştır; çok-seed (42/123/2023) ortalama±std analizi gelecek çalışmaya bırakılmıştır.
- Gemma-4 için modele özel hiperparametre araması (LR, epoch sayısı, hedef modüller) yapılmamıştır; ortak reçete tüm modellere uygulanmıştır. Modele özel optimizasyonla Gemma-4'ün skoru muhtemelen artırılabilir.
- Twitter kullanıcı tabanı genel nüfusu temsil etmez (yaş, kentsel/kırsal, dil yetkinliği yanlılığı).
- Çıkarım süreleri T4 üzerinde bf16/fp16 emülasyonu ile ölçülmüştür; edge cihaz performansını birebir yansıtmayabilir.

8.3. Etik Değerlendirme

- Bağlamsal bütünlük: Veriler yalnızca akademik amaçla kullanılmış, kullanıcı etiketleri anonimleştirilmiştir.
- Karar destek aracı: Sistem tek başına karar verici değildir; insan operatör onayı esastır.
- Açık kaynak ve tekrarlanabilirlik: Tüm kod ve hiperparametreler paylaşılmış, seed=42 ile sonuçlar yeniden üretilebilir kılınmıştır.

8.4. Gelecek Çalışmalar

- Gemma-4-E2B için modele özel hiperparametre araması (epoch=1-2, lr=1e-4) ile aşırı uydurmanın azaltılması.
- Üç seed ile ortalama±std raporlaması ve few-shot (3-shot) temel çizgi.
- Saliha'nın LoRA sonuçlarıyla tam LoRA-QLoRA karşılaştırması.
- Veri setinin büyütülmesi ve gerçek zamanlı (stream) entegrasyon.

Kaynakça

- [1] Küçüktaş, U. T. (2023). Turkey Earthquake Relief Tweets Dataset. Kaggle. <https://www.kaggle.com/datasets/ulkutuncerkucuktas/turkey-earthquake-relief-tweets-dataset> (bu çalışmada kullanılan ham tweet kaynağı)
- [2] Toraman, C., et al. (2023). Tweets Under the Rubble: Detection of Messages Calling for Help in Earthquake Disaster. arXiv:2302.13403. (ilgili literatür)
- [3] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS 2023.
- [4] Hu, E. J., et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.
- [5] Allal, L. B., et al. (2024). SmoLLM2: Data-Centric Training of a Small Language Model. arXiv:2502.02737.
- [6] Zhang, P., et al. (2024). TinyLlama: An Open-Source Small Language Model.
- [7] Qwen Team, Alibaba (2024). Qwen2.5 Technical Report.
- [8] Google DeepMind (2024–2026). Gemma Open Models (Gemma 2, 3n, 4).